Практическое занятие №5

Вариант №1

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Определите модуль разницы между средними тратами женщин и мужчин (трата – отрицательное значение amount). Выведите ответ в виде вещественного числа, округлённого до двух знаков после запятой, отделив дробную часть точкой в формате "123.45". Создайте новый столбец – mcc_code+tr_type, сложив значения из соответствующих столбцов.

Пояснения:

- Если в результате для мужчин получились значения [-1,-3,-5], а для женщин [-1,-2,-3], то модуль разницы между средними арифметическими -3 и -2 будет равен 1.
- Для вычисления модуля разности точных знаний о том, какой класс относится к мужчинам, а какой – к женщинам, не требуется.
- Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.

2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу amount). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Измените тип поля tr_day на int. Выберите из transactions все MCC коды, которые встретились в выборке более чем 60000 раз. Сгруппируйте отфильтрованный датафрейм по дню и MCC-коду, получая средние значения суммы amount. Отрисуйте зависимость средних сумм (может пригодится метод unstack()) по каждому из MCC-кодов по дням. Проверьте верно ли, что 2 из полученных MCC-кодов связаны с финансовыми институтами.

Пояснение: Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма - .str.split(), например. Либо же реализовывать логику выделения подстроки с помощью метода apply.

Вариант №2

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – mcc_code+tr_type, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод .astype(str) для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением amount. Посчитайте средние значения по категориям получившегося столбца mcc_code+tr_type, в которых количество наблюдений >=5 и <=25. Выведите ответ в виде вещественного числа, округлённого до 2-х знаков после запятой.

2. По данным полученной таблицы изобразите гистограмму.

Вариант №3

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – mcc_code+tr_type, сконкатенировав значения из соответствующих столбцов. Оставьте только наблюдения с отрицательным значением amount. Посчитайте дисперсию по категориям получившегося столбца mcc_code+tr_type, в которых количество наблюдений >= 10. Определите отношение максимальной дисперсии к минимальной. Выведите ответ в виде вещественного числа, округлённого до ближайшего целого в формате "123456" без дробной части.
   Пояснения:
   - Для конкатенации значений в столбцах нужно применить apply к строкам датафрейма, прописывая логику преобразования и конкатенации значений внутри.
   - Для одновременного подсчета количества наблюдений и дисперсии по категориям можно воспользоваться функцией .agg().

2. По данным полученной таблицы изобразите составную столбчатую диаграмму на основе нескольких серий.

Вариант №4

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу amount) отдельно для мужчин и женщин (назовите ее "max_income"). Оставьте по 6 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям "max_income". Выделите среди них те, которые не встречаются одновременно у мужчин и у женщин.
   Пояснение: если максимальные суммы приходов по каким-то типам были равны [1,2,3,4,5,6,7,8], то 5 максимальных из них: [4,5,6,7,8].

2. По данным полученной таблицы изобразите диаграмму рассеивания.

Вариант №5

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу amount) отдельно для мужчин и женщин (назовите ее "max_income"). Оставьте по 5 транзакций для мужчин и для женщин, наименьших среди всех транзакций по полученным значениям "max_income". Выделите среди них те, которые встречаются одновременно и у мужчин, и у женщин.
   Пояснение: если максимальные суммы приходов по каким-то типам были равны [1,2,3,4,5,6,7,8], то 5 минимальных из них: [1,2,3,4,5].

2. По данным полученной таблицы изобразите составную горизонтальную столбчатую диаграмму на основе нескольких серий.

Вариант №6

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Отфильтруйте строки таким образом, чтобы оставить только те транзакции, у которых в соответствующий относительный день tr_day количество уникальных MCC кодов при транзакциях было больше 75 (можно воспользоваться функцией nunique()). Сгруппируйте полученный отфильтрованный датафрейм по MCC коду и полу, после чего, проанализировав результат, определите женщины или мужчины относятся к gender == 0.
   Пояснения:
   - Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма – .str.split(), например. Либо же реализовывать логику выделения подстроки с помощью метода apply.
   - Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или приходов в них.

2. По данным полученной таблицы изобразите столбчатую диаграмму на основе нескольких серий.

Вариант №7

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Разбейте расходы (отрицательные значения сумм) на 5 бакетов amount_bucket равного объёма (с помощью pd.qcut), разбив все траты на категории 'Very High', 'High', 'Middle', 'Low', 'Very Low'. Оставшиеся неотрицательные траты отнесите к категории 'Income' (воспользуйтесь функцией .cat.add_categories('Income') для того, чтобы добавить новую категорию 'Income' к категориям 'Very High', 'High', 'Middle', 'Low', 'Very Low', а затем заполните пустые значения новой категорией).
   Пояснение: в категории Very High должны оказаться максимальные по модулю отрицательные транзакции.

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются мужскими;
- посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств женщинам в целом больше, чем мужчинам.

Вариант №8

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только положительные суммы прихода на карту (положительные суммы по столбцу amount). Из поля tr_datetime выделите час tr_hour, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол gender, индексы – tr_hour, столбцы – amount_bucket.
   Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Нужно воспользоваться функциями str.split() и .apply(lambda x: x[]).

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

   Проверьте действительно ли:

- самые низкие траты в 3 часа ночи осуществляются в более 70% случаев женщинами;
- существуют особые часы в мелких тратах, когда женщины тратят намного больше мужчин (>80%).

Вариант №9

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только отрицательные суммы прихода на карту (отрицательные суммы по столбцу amount). Из поля tr_datetime выделите час tr_hour, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол gender, индексы – tr_hour, столбцы – amount_bucket.
   Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Можно воспользоваться функциями str.find() и .apply(lambda x: x[]).

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

   Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются мужскими;
- посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств женщинам в целом больше, чем мужчинам.

Вариант №10

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только положительные суммы прихода на карту (положительные суммы по столбцу amount). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Измените тип поля tr_day на int. Выберите из transactions все MCC коды, которые встретились в выборке более чем 60000 раз. Сгруппируйте отфильтрованный датафрейм по дню и MCC-коду, получая средние значения суммы amount.

2. Далее отрисуйте зависимость средних сумм (может пригодится метод unstack()) по каждому из MCC-кодов по дням.
   Проверьте действительно ли:
   - бакалейные магазины обладают максимальными средними тратами среди выбранных MCC-кодов;
   - денежные переводы имеют как минимум 3 явных минимума средних.

   Пояснения:
   - Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма - .str.split(), например. Либо же реализовывать логику выделения подстроки с помощью метода apply.

Вариант №11

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу amount) отдельно для мужчин и женщин (назовите ее "max_income"). Оставьте по 10 транзакций для мужчин и для женщин, наименьших среди всех транзакций по полученным значениям "max_income". Выделите среди них те, которые встречаются одновременно и у мужчин, и у женщин.

2. По данным полученной таблицы изобразите составную круговую диаграмму на основе нескольких серий.

Вариант №12

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Определите модуль разницы между средними тратами женщин и мужчин (трата – отрицательное значение amount). Выведите ответ в виде вещественного числа, округлённого одного знака после запятой, отделив дробную часть точкой в формате "123.4". Создайте новый столбец – mcc_code+tr_type, сложив значения из соответствующих столбцов.
   Пояснения:
   - Если в результате для мужчин получились значения [-1,-3,-5], а для женщин [-1,-2,-3], то модуль разницы между средними арифметическими -3 и -2 будет равен 1.
   - Для вычисления модуля разности точных знаний о том, какой класс относится к мужчинам, а какой – к женщинам, не требуется.
   - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.

2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу amount). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Измените тип поля tr_day на int. Измените тип поля tr_day на int. Выберите из transactions все MCC коды, которые встретились в выборке более чем 55000 раз. Сгруппируйте отфильтрованный датафрейм по дню и MCC-коду, получая средние значения суммы amount. Отрисуйте зависимость средних сумм (может пригодится метод unstack()) по каждому из MCC-кодов по дням. Проверьте верно ли, что 2 MCC кода, связанные со снятием наличности имеют в целом разные знаки (в одном случае почти везде – траты, в другом – пополнения.

.

Вариант №13

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – mcc_code+tr_type, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод .astype(str) для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением amount. Посчитайте средние значения по категориям получившегося столбца mcc_code+tr_type, в которых количество наблюдений >=4 и <=30. Выведите ответ в виде вещественного числа, округлённого до 3-х знаков после запятой.

2. По данным полученной таблицы изобразите гистограмму в нормированном виде (показывающую дискретизированную плотность, а поверх неё график ядерной оценки плотности).

Вариант №14

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только отрицательные суммы прихода на карту (отрицательные суммы по столбцу amount). Из поля tr_datetime выделите час tr_hour, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол gender, индексы – tr_hour, столбцы – amount_bucket.
   Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Можно воспользоваться функциями str.find() и .apply(lambda x: x[]).

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

   Проверьте действительно ли:
- ночные поступления денег (01-05 часов) в более чем 85% случаев являются женскими;
- самые низкие траты в 3 часа ночи осуществляются в более 70% случаев женщинами.

Вариант №15

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу amount) отдельно для мужчин и женщин (назовите ее "max_income"). Оставьте по 10 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям "max_income". Выделите среди них те, которые встречаются одновременно у мужчин и у женщин.

2. Визуализируйте на рисунке данные полученной таблицы.

Вариант №16

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Определите какой класс относится к мужчинам, а какой – к женщинам, и вычислите модуль разницы между их средними тратами (трата – отрицательное значение amount). Выведите ответ в виде вещественного числа, округлённого до трех знаков после запятой. Создайте новый столбец – mcc_code+tr_type, сложив значения из соответствующих столбцов.

   Пояснения:

   - Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или приходов в них.
   - Если в результате для мужчин получились значения [-1,-3,-5], а для женщин [-1,-2,-3], то модуль разницы между средними арифметическими -3 и -2 будет равен 1.
   - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.

2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу amount). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Измените тип поля tr_day на int. Выберите из transactions все MCC коды, которые встретились в выборке более чем 55000 раз. Сгруппируйте отфильтрованный датафрейм по дню и MCC-коду, получая средние значения суммы amount. Отрисуйте зависимость средних сумм (может пригодится метод unstack()) по каждому из MCC-кодов по дням. Проверьте верно ли, что денежные переводы имеют как минимум 3 явных минимума средних.
   Пояснение: Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма - .str.split(), например. Либо же реализовывать логику выделения подстроки с помощью метода apply.

Вариант №17

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – mcc_code+tr_type, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод .astype(str) для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением amount. Посчитайте средние значения по категориям получившегося столбца mcc_code+tr_type, в которых количество наблюдений >=5 и <=30. Выведите ответ в виде вещественного числа, округлённого до 2-х знаков после запятой.

2. По данным полученной таблицы изобразите круговую диаграмму.

Вариант №18

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – mcc_code+tr_type, сконкатенировав значения из соответствующих столбцов. Оставьте только наблюдения с отрицательным значением amount. Посчитайте дисперсию по категориям получившегося столбца mcc_code+tr_type, в которых количество наблюдений >= 5. Определите отношение максимальной дисперсии к минимальной. Выведите ответ в виде вещественного числа, округлённого до ближайшего целого без дробной части.
   Пояснения:
   - Для конкатенации значений в столбцах нужно применить apply к строкам датафрейма, прописывая логику преобразования и конкатенации значений внутри.
   - Для одновременного подсчета количества наблюдений и дисперсии по категориям можно воспользоваться функцией .agg().

2. По данным полученной таблицы изобразите составную горизонтальную столбчатую диаграмму на основе нескольких серий.

Вариант №19

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Разбейте расходы (отрицательные значения сумм) на 5 бакетов amount_bucket равного объёма (с помощью pd.qcut), разбив все траты на категории 'Very High', 'High', 'Middle', 'Low', 'Very Low'. Оставшиеся неотрицательные траты отнесите к категории 'Income' (воспользуйтесь функцией .cat.add_categories('Income') для того, чтобы добавить новую категорию 'Income' к категориям 'Very High', 'High', 'Middle', 'Low', 'Very Low', а затем заполните пустые значения новой категорией).
   Пояснение: в категории Very High должны оказаться максимальные по модулю отрицательные транзакции.

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются мужскими;
- существуют особые часы в мелких тратах, когда женщины тратят намного больше мужчин (>80%).

Вариант №20

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу amount) отдельно для мужчин и женщин (назовите ее "max_income"). Оставьте по 20 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям "max_income". Выделите среди них те, которые встречаются одновременно и у мужчин, и у женщин.
   Пояснение: если максимальные суммы приходов по каким-то типам были равны [1,2,3,4,5,6,7,8], то 5 максимальных из них: [4,5,6,7,8].

2. По данным полученной таблицы изобразите гистограмму.

Вариант №21

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Отфильтруйте строки таким образом, чтобы оставить только те транзакции, у которых в соответствующий относительный день tr_day количество уникальных MCC кодов при транзакциях было больше 70 (можно воспользоваться функцией nunique()). Сгруппируйте полученный отфильтрованный датафрейм по MCC коду и полу, после чего, проанализировав результат, определите женщины или мужчины относятся к gender == 1.
   Пояснения:
   - Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма – .str.split(), например. Либо же реализовывать логику выделения подстроки с помощью метода apply.
   - Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или приходов в них.

2. По данным полученной таблицы изобразите столбчатую диаграмму на основе нескольких серий.

Вариант №22

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – mcc_code+tr_type, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод .astype(str) для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением amount. Посчитайте средние значения по категориям получившегося столбца mcc_code+tr_type, в которых количество наблюдений >=5 и <=35. Выведите ответ в виде вещественного числа, округлённого до 2-х знаков после запятой.

2. По данным полученной таблицы изобразите график ядерной оценки плотности.

Вариант №23

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только положительные суммы прихода на карту (положительные суммы по столбцу amount). Из поля tr_datetime выделите час tr_hour, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол gender, индексы – tr_hour, столбцы – amount_bucket.
   Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Нужно воспользоваться функциями str.split() и .apply(lambda x: x[]).

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- Посмотрев на долю мужчин в максимальных тратах средств (Very High), можно сделать вывод, что количество высоких трат в каждый возможный час у мужчин больше, чем у женщин;
- Посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств женщинам в целом больше, чем мужчинам.

Вариант №24

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Разбейте расходы (отрицательные значения сумм) на 5 бакетов amount_bucket равного объёма (с помощью pd.qcut), разбив все траты на категории 'Very High', 'High', 'Middle', 'Low', 'Very Low'. Оставшиеся неотрицательные траты отнесите к категории 'Income' (воспользуйтесь функцией .cat.add_categories('Income') для того, чтобы добавить новую категорию 'Income' к категориям 'Very High', 'High', 'Middle', 'Low', 'Very Low', а затем заполните пустые значения новой категорией).
   Пояснение: в категории Very High должны оказаться максимальные по модулю отрицательные транзакции.

2. Отрисуйте полученные результаты, передав их в функцию plot_pivot_table, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств мужчинам в целом больше, чем женщинам.
- самые низкие траты в 3 часа ночи осуществляются в более 80% случаев мужчинами.

Вариант №25

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). Определите какой класс относится к мужчинам, а какой – к женщинам, и вычислите модуль разницы между их средними тратами (трата – отрицательное значение amount). Выведите ответ в виде вещественного числа, округлённого до двух знаков после запятой. Создайте новый столбец – mcc_code+tr_type, сложив значения из соответствующих столбцов.

   Пояснения:

   - Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или приходов в них.
   - Если в результате для мужчин получились значения [-1,-3,-5], а для женщин [-1,-2,-3], то модуль разницы между средними арифметическими -3 и -2 будет равен 1.
   - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.

2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу amount). Выделите из поля tr_datetime относительный день tr_day (первое число до точного времени). Измените тип поля tr_day на int. Измените тип поля tr_day на int. Выберите из transactions все MCC коды, которые встретились в выборке более чем 50000 раз. Сгруппируйте отфильтрованный датафрейм по дню и MCC-коду, получая средние значения суммы amount. Отрисуйте зависимость средних сумм (может пригодится метод unstack()) по каждому из MCC-кодов по дням. Проверьте верно ли, что бакалейные магазины обладают максимальными средними тратами среди выбранных MCC-кодов.

.

Вариант №26

1. Считайте в переменные tr_mcc_codes, tr_types, transactions и customers_gender_train из одноимённых таблиц из папки data. В transactions считайте только первые 1000000 строк. Соедините transactions со всеми остальными таблицами (tr_mcc_codes, tr_types, gender_train). Причём с customers_gender_train необходимо смёрджиться с помощью left join, а с оставшимися датафреймами – через inner (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу amount) отдельно для мужчин и женщин (назовите ее "max_income"). Оставьте по 20 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям "max_income". Выделите среди них те, которые встречаются одновременно у мужчин и у женщин.

2. Визуализируйте данные полученной таблицы с помощью круговой диаграммы.

Описание данных

Таблица `transactions.csv`

Описание

Таблица содержит историю транзакций клиентов банка за один год и три месяца.

Формат данных

```
customer_id,tr_datetime,mcc_code,tr_type,amount,term_id
111111,15 01:40:52,1111,1000,-5224,111111
111112,15 15:18:32,3333,2000,-100,11122233
...
```

Описание полей

- `customer_id` — идентификатор клиента;
- `tr_datetime` — день и время совершения транзакции (дни нумеруются с начала данных);
- `mcc_code` — mcc-код транзакции;
- `tr_type` — тип транзакции;
- `amount` — сумма транзакции в условных единицах со знаком; `+` — начисление средств клиенту (приходная транзакция), `-` — списание средств (расходная транзакция);
- `term_id` — идентификатор терминала;

Таблица `gender_train.csv`

Описание

Данная таблица содержит информацию по полу для части клиентов, для которых он известен. Для остальных клиентов пол неизвестен.

Формат данных

```
customer_id,gender
111111,0
111112,1
...
```

Описание полей

- `customer_id` — идентификатор клиента;
- `gender` — пол клиента;

Таблица `tr_mcc_codes.csv`

Описание

Данная таблица содержит описание mcc-кодов транзакций.

Формат данных

```
mcc_code;mcc_description
1000;словесное описание mcc-кода 1000
2000;словесное описание mcc-кода 2000
...
```

Описание полей

- `mcc_code` – mcc-код транзакции;
- `mcc_description` — описание mcc-кода транзакции.

Таблица `tr_types.csv`

Описание

Данная таблица содержит описание типов транзакций.

Формат данных

```
tr_type;tr_description
1000;словесное описание типа транзакции 1000
2000;словесное описание типа транзакции 2000
...
```

Описание полей

- `tr_type` – тип транзакции;
- `tr_description` — описание типа транзакции;

Ссылка для скачивания файлов:
https://cloud.mail.ru/public/L2DU/UNuECvB1g